



UNIVERSIDADE ESTADUAL DO CEARÁ

CENTRO DE CIÊNCIA E TECNOLOGIA

CURSO DE GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO
DISCIPLINA DE EXTENSÃO III

RELATÓRIO FINAL - SISTEMA SMARTFLOW AI

Equipe de Desenvolvimento

Francisco Gabriel Machado Albuquerque

Jaime Silva de Abreu

João Antônio Meneses

FORTALEZA - CEARÁ

2026

Conteúdo do Relatório

Seção do Documento	Página
1. Introdução	3
2. PARTE I - 18/04/2026	3
2.1 Definição do Projeto e Oportunidade de Mercado	3
2.2 Arquitetura de LLMs, Engenharia de Prompt e RAG	4
2.3 Próximos Passos Consolidados	4
3. PARTE II - 28/04/2026	5
3.1 Desenvolvimento do Projeto e Divisão de Escopo	5
3.2 Decisões Técnicas e Arquitetura Multi-SaaS	5
3.3 Soluções de Engenharia Encontradas	6
3.4 Próximos Passos de Consolidação	6
4. PARTE III - 28/05/2026	6
4.1 Implementação de Novas Funcionalidades Autônomas	6
4.2 Otimização Avançada de Prompts e Recuperação	7

Seção do Documento	Página
4.3 Decisões Finais, Segurança e Integração PGVector	7
4.4 Soluções para Limitação de Escopo Tecnológico	8
5. Próximos Passos - Além da Cadeira de Extensão III	8
6. Considerações Finais	9

1. Introdução

Este relatório documenta a trajetória completa de concepção, especificação técnica e desenvolvimento do projeto SmartFlow AI, concebido ao longo da disciplina de Extensão III. A proposta consiste em uma plataforma estruturada sob o modelo de Software as a Service (SaaS) com o objetivo de democratizar o acesso e a criação de chatbots baseados em inteligência artificial conversacional avançada.

Diferenciando-se das soluções tradicionais de atendimento automatizado, que dependem de fluxogramas estáticos e menus numéricos engessados, o SmartFlow AI oferece uma interface fluida baseada em Modelos de Linguagem de Larga Escala (LLMs). O sistema permite que o usuário final gerencie de forma autônoma suas instâncias de atendimento, personifique respostas via instruções customizadas e construa uma base robusta de conhecimento dinâmico sem a necessidade de habilidades prévias de programação.

2. PARTE I - 18/04/2026

2.1 Definição do Projeto e Oportunidade de Mercado

No marco inicial do projeto, a equipe identificou uma dor recorrente no mercado de soluções digitais corporativas e acadêmicas: a ineficiência crônica do atendimento baseado em árvores de decisão e o alto custo para escalar o suporte humano. A proposta inicial visava arquitetar um chatbot que respondesse aos usuários finais de maneira dinâmica a partir de um contexto pré-estabelecido.

Nas primeiras implementações experimentais do protótipo, o sistema utilizava uma estrutura básica de conversação contínua (*ConversationChain*). Contudo, os testes práticos demonstraram uma severa vulnerabilidade técnica associada à dependência do prompt fixo. Para que a inteligência artificial respondesse com precisão sobre regras de negócio específicas, todos os dados precisavam ser

inseridos diretamente na janela de instruções estruturais. Esse formato limitava severamente a escalabilidade da solução, além de gerar custos operacionais elevados de processamento de tokens e lentidão decorrente do esgotamento precoce da janela de contexto (*context window*).

2.2 Arquitetura de LLMs, Engenharia de Prompt e RAG

Para mitigar o problema do limite de contexto e eliminar alucinações das respostas da inteligência artificial, a equipe realizou estudos teóricos e práticos com foco na modelagem contextual. A decisão conceitual mais importante dessa fase foi abandonar a interface de resposta linear para adotar o paradigma de **Agentes Inteligentes** integrados à arquitetura de Geração Aumentada de Recuperação (*RAG - Retrieval-Augmented Generation*).

Sob essa nova lógica, o modelo de inteligência artificial passou a operar associado a uma ferramenta especializada de busca (*Retriever Tool*). Em vez de armazenar todas as diretrizes organizacionais no prompt do sistema, as informações corporativas e acadêmicas foram convertidas em vetores numéricos estruturados. Desse modo, o agente primeiro interpreta a intenção da dúvida enviada pelo usuário, executa uma consulta cirúrgica ao banco vetorial e extrai exclusivamente os trechos pertinentes para enriquecer o contexto de geração final da resposta. Os resultados iniciais comprovaram maior assertividade conceitual, respostas coerentes e eliminação completa de desvios informacionais (alucinações).

2.3 Próximos Passos Consolidados

1. Evoluir a arquitetura técnica local para um modelo distribuído e desacoplado em serviços independentes (Back-end e Front-end).
2. Projetar e mapear endpoints assíncronos que garantam tempos de resposta otimizados para as chamadas de chat web em tempo real.
3. Desenvolver uma interface web administrativa e amigável (Dashboard) para o gerenciamento autônomo das instâncias de chatbots por parte de múltiplos usuários clientes.

3. PARTE II - 28/04/2026

3.1 Desenvolvimento do Projeto e Divisão de Escopo

Com as especificações conceituais validadas nas reuniões preliminares, a equipe iniciou a fase física de engenharia de software da segunda versão da plataforma SmartFlow AI. O ecossistema foi estruturado sob uma divisão modular rigorosa de escopo para garantir alta estabilidade operacional, facilidade de manutenção e suporte multitenant (múltiplas contas corporativas isoladas):

- **Motor Back-end (Engine de IA):** Desenvolvido inteiramente em Python através do microframework **FastAPI** e rodando sob o servidor de alto desempenho **Uvicorn**. Este componente atua como o núcleo lógico, consumindo os modelos do framework **LangChain** para realizar a orquestração dinâmica da memória conversacional e gerenciamento dinâmico de histórico de chat.
- **Painel Administrativo SaaS (Front-end):** Construído sob o framework **Flask** em associação com

o mecanismo de renderização de templates **Jinja2** e estilização baseada no framework Bootstrap

4. Este painel serve de vitrine operacional onde os gestores gerenciam seus tokens, visualizam a captação estruturada de novos leads de usuários e configuram as personas de cada agente de IA.

3.2 Decisões Técnicas e Arquitetura Multi-SaaS

A escolha de segmentar a infraestrutura lógica do software trouxe benefícios técnicos fundamentais à aplicação. O isolamento completo entre o painel corporativo em Flask e as requisições assíncronas em FastAPI evitou gargalos críticos de concorrência. Mesmo que a interface administrativa web enfrente picos excessivos de acessos simultâneos por gestores de contas, o motor principal que processa as mensagens de chat dos usuários finais permanece operando continuamente sem degradação de performance.

Para a persistência robusta dos dados relacionais (estruturas de usuários, logs de auditoria e credenciais protegidas), a equipe optou pela adoção do banco de dados **PostgreSQL** gerenciado na nuvem via plataforma **Supabase**. A comunicação nativa do Python com a base relacional foi otimizada com o uso do ORM SQLAlchemy e do driver psycopg2, eliminando a injeção manual de queries SQL puras e acelerando as rotinas internas.

3.3 Soluções de Engenharia Encontradas

Uma das melhores soluções de engenharia implementadas nesta entrega envolveu a mitigação antecipada de riscos de vazamento de segredos industriais e credenciais. Através do uso da biblioteca especializada cryptography com o algoritmo de criptografia simétrica robusta **Fernet**, todas as chaves de API externas dos clientes foram criptografadas tanto em trânsito quanto em repouso dentro do PostgreSQL, assegurando blindagem nativa contra invasões de banco de dados.

Para otimizar o fluxo de trabalho colaborativo, o grupo solucionou problemas iniciais de integração de código instituindo ramos paralelos (*branches*) bem definidas no ambiente virtual do GitHub para o Front e para o Back-end, acoplando as funcionalidades com estabilidade apenas após a conclusão de baterias intensivas de testes locais de API em formato JSON utilizando mocks de requisições estruturadas.

3.4 Próximos Passos de Consolidação

1. Implementar mecanismos interativos e visuais de carregamento (*loading states*) no front-end web para enriquecer a experiência do usuário durante o envio de requisições pesadas de IA.
2. Disponibilizar recursos para atualização dinâmica e autônoma da base interna de dados dos bots diretamente na interface gráfica.
3. Avançar no design conceitual de segurança no armazenamento de dados baseados em vetores contextuais.

4. PARTE III - 28/05/2026

4.1 Implementação de Novas Funcionalidades Autônomas

A fase final do projeto coroou a maturidade da aplicação com a inserção de features avançadas focadas na autonomia total do usuário e na visibilidade operacional do ecossistema SaaS do SmartFlow AI:

- **Upload de Arquivos na Interface:** Inclusão de um módulo visual de upload direto nos cards gerenciais de cada bot no painel Flask. O usuário administrativo realiza o envio autônomo de manuais, guias ou cartilhas institucionais em formato PDF ou TXT. O sistema capta o arquivo, realiza a quebra em blocos semânticos de texto (*chunkenization*) e alimenta a inteligência artificial sem necessidade de qualquer alteração de código ou interação via terminal.
- **Agente Inteligente com Tool de Feedback Dinâmico:** Caso o chatbot web não localize a resposta para uma pergunta complexa do usuário final dentro de sua base de conhecimento vetorizada, o agente inteligente aciona automaticamente uma ferramenta interna (*Tool de Feedback*). Esta ferramenta gera um log estruturado em arquivo de formato .txt detalhando as lacunas de informação identificadas, municiando o dono do chatbot com os tópicos exatos que precisam ser adicionados na próxima atualização de documentos da empresa.

4.2 Otimização Avançada de Prompts e Recuperação

Na engenharia de prompt atualizada, o *system prompt* evoluiu significativamente. Em vez de operar apenas como um filtro sintático básico, o modelo de linguagem natural foi configurado para interpretar os conceitos extraídos de maneira heurística. O prompt estrutural instrui a inteligência artificial a adotar o material de referência vetorial como base norteadora de conhecimento, extraindo e cruzando os conceitos sem realizar cópias literais ou citações diretas enfadonhas. O agente prioriza o raciocínio clínico, interpretação semântica avançada e respostas concisas aplicadas ao tom de voz corporativo definido pelo cliente no dashboard.

4.3 Decisões Finais, Segurança e Integração PGVector

Do ponto de vista da segurança em infraestruturas compartilhadas (SaaS), o projeto atingiu robustez corporativa através da ativação do mecanismo de **Row-Level Security (RLS)** nativo no banco do Supabase conectado à extensão de busca vetorial **PGVector**. Cada conjunto de embeddings gerado recebe uma amarração atômica associada ao identificador unívoco daquela conta corporativa (ID do Bot). Essa engenharia assegura isolamento lógico absoluto: o robô web de um cliente corporativo é estruturalmente incapaz de consultar ou vaziar dados contidos nas bases vetoriais de outros assinantes da plataforma.

Adicionalmente, refinou-se o algoritmo de vetorização no back-end para realizar varreduras prévias (hash de arquivos). Caso um gestor envie um documento que já consta indexado na base do PGVector, o sistema recusa a operação repetida de maneira inteligente, economizando processamento de hardware, otimizando o consumo de tokens da API de embeddings da Google e agilizando as rotinas de indexação de novos conteúdos.

4.4 Soluções para Limitação de Escopo Tecnológico

Durante os testes de estresse computacional com arquivos massivos, a equipe deparou-se com o risco de esgotamento de limites de requisições de tokens por minuto nas requisições do modelo. Para contornar essa restrição sem comprometer os objetivos da cadeira de Extensão III, estruturou-se uma

rotina adaptativa de fragmentação inteligente dos blocos de textos antes do envio à camada RAG.

Ao mesmo tempo, para mitigar o tempo longo gasto em resoluções automáticas de bibliotecas conflitantes entre versões do ecossistema Python, o ecossistema completo foi isolado e encapsulado através de um ambiente virtual controlado (venv), garantindo que a aplicação rode com estabilidade máxima e possa ser replicada sem erros em quaisquer servidores de produção em ambiente de nuvem.

5. Próximos Passos - Além da Cadeira de Extensão III

Visando expandir o ecossistema estável construído no MVP acadêmico para transformá-lo em uma solução comercial real após o encerramento do semestre letivo, delineou-se um planejamento de novos módulos funcionais:

- **Deploy de Alta Disponibilidade em Cloud 24/7:** Hospedar de forma definitiva as instâncias do FastAPI e do Flask em provedores de nuvem robustos com configuração ativa de certificados SSL digitais, monitoramento integrado e escalonamento vertical sob demanda.
- **Lançamento de Programa Piloto Beta:** Implementar a plataforma em um cenário prático real com um usuário beta selecionado no mercado regional, visando coletar métricas empíricas de taxas de engajamento, satisfação de uso e conversão de leads diretamente na interface corporativa.
- **Adoção de Recursos de IA Multimodal:** Expandir as capacidades analíticas dos Agentes Inteligentes integrados ao painel do SmartFlow AI para receber, transcrever e interpretar dados multimodais, possibilitando a geração autônoma de resumos a partir de arquivos de áudio enviados pelos usuários.

6. Considerações Finais

O desenvolvimento da plataforma SmartFlow AI constituiu uma vivência pedagógica e prática profundamente enriquecedora para todo o grupo de alunos de Ciência da Computação. O projeto transpôs as barreiras teóricas convencionais de chamadas simples de APIs externas, desafiando a equipe a consolidar uma arquitetura de microsserviços distribuída, resiliente e perfeitamente aderente às premissas corporativas modernas de engenharia de software Full Stack.

No âmbito tecnológico, a imersão nos fundamentos de Large Language Models (LLMs) associados ao ecossistema de busca vetorial (PGVector, Supabase e RAG) propiciou um entendimento sólido sobre como mitigar comportamentos imprevisíveis de modelos inteligentes através de contextos dinâmicos e controle rigoroso de acesso modular. Tais aprendizados qualificam os membros do grupo perante as demandas reais e mais competitivas da indústria global de software e inteligência artificial generativa.

Por fim, externamos o nosso sincero agradecimento à mentoria do corpo docente da disciplina de Extensão III, cujos direcionamentos estratégicos foram cruciais para a evolução da maturidade operacional do sistema. O SmartFlow AI encerra este ciclo letivo consolidado como uma ferramenta estável, robusta e provida de ampla viabilidade prática de mercado.